

Уncial

Розпізнавання тексту

Розділ 1. Письмо та шрифт

Унціал — це маюскульне книжкове письмо, яким переписували рукописи з четвертого по восьме століття. Його літери округлі й окремі, а не злиті, тому їх легко читати навіть через півтори тисячі років після написання.

Саме тому назва підходить бібліотеці розпізнавання: усе тут про те, щоб текст можна було прочитати.

Розділ 2. Письмо та шрифт

Скановані документи не мають текстового шару, тому єдиний спосіб дістати з них текст — оптичне розпізнавання. Рушій повертає рядки з координатами та впевненістю.

Українська мова записується кирилицею, і це відразу відсікає частину рушіїв: ML Kit моделі для кирилиці не має зовсім.

Розділ 3. Письмо та шрифт

Реконструкція структури перетворює геометрію назад у сенс: рядок, більший за медіану, стає заголовком, а вертикальний проміжок означає новий абзац.

Колонтитули та номери сторінок відкидаються, бо вони повторюються і не є частиною тексту. Page 3 of 3.